# Proyecto Final de Ingeniería de Datos A data-driven analysis of Argentinian wages and household economics in 2019

William Sebastián Cabrera Buitrago
Paola Andrea Cortés Montes
Andrés Felipe Miranda Mendoza
Sara Sofía Torres Méndez
Simón Vélez Castillo

Profesor: Javier Casas Salgado

Universidad del Rosario Ingeniería de Datos 2024 - I

## Descripción

#### **Problema**

Se dispone de un conjunto de datos que contiene información demográfica y socioeconómica de Argentina en el 2019, sujeta a ciertas restricciones y reglas. El objetivo es realizar un análisis detallado de estos datos para responder a una serie de preguntas relacionadas con los ingresos, la educación, el estado conyugal, la situación laboral y otros aspectos relevantes de la población. El enfoque principal está orientado a entender los distintos factores que influyen en la obtención de salarios elevados, identificando así las variables determinantes en el panorama socioeconómico del país.

## **Reglas**

- Una persona puede tener solo un estado conyugal a la vez
- En cada hogar debe haber por lo menos un miembro.
- En cada una casa(id) puede haber un hogar o más.
- Cada hogar solo debe tener un jefe.
- Los años de escolaridad no pueden ser mayor a la edad de la persona.
- Todos los ingresos de las personas son no negativos.
- El sexo de las personas solo puede ser mujer o varón.
- El id de cada casa es único.
- Cada miembro debe tener un hogar.
- Cada hogar debe tener una casa (Id).

#### **Preguntas**

- ¿Cuáles son los ingresos de las personas las cuales han terminado sus estudios universitarios a comparación de aquellas personas que no la han completado?
- ¿Cómo compara la situación laboral de la gente que vive con sus padres versus quienes no?
- ¿En promedio cuantos ingresos de familias cuya cabeza de hogar sea mujer superan el salario mínimo en argentina durante el 2019?
- ¿Como se comparan los ingresos familiares y el salario entre universidad privada y pública?
- ¿Qué lugar de nacimiento (de los presentes en la encuesta) cuenta con los mayores salarios?

- ¿Las familias más grandes tienden a tener una mejor, igual o peor educación que las familias más pequeñas?
- ¿Las personas con ingresos familiares per cápita superiores a la media tienen salarios superiores a la media?

#### Análisis.

.

#### • Entidades:

- Hogar (fuerte):se refiere al hogar de la familia encuestada sus atributos son dominio, comuna, id, casa\_id\_fk, ingresos\_familiares, numero\_hogar,calidad\_ingresos familiares.
- Miembro (Fuerte): es una persona de alguna de las familias encuestadas;sus atributos son id\_miembro, numero\_hogar\_fk,
   sexo,edad,num miembros,parentesco,situacion sent,id casa fk
- Tipo ingresos (Débil): Da información acerca de la situación economica de una persona;sus atributos son estado\_ocup, cat\_ocup, aporte\_ingreso\_fami, ingreso\_tot\_nolab, ingreso\_tot\_lab,calidad\_ingre\_ocup, calidad\_tot\_nolab, calidad\_ingresos\_totales,ingresos\_totales, ingreso\_per\_capita\_familiar, id2\_miemmbro\_pk
- Educación (Débil): Da informacion del nivel academico de una persona; la sus atributos son años\_Escolaridad, nivel\_max\_educativo,nivel\_actual, sector\_educativo, id1\_miembro\_pk, estado\_educativo
- Salud (Débil): aporta informacion medica de la personasus atributos son hijos\_nacidos,cant\_hijos\_nacidos, afiliacion\_salud, ligar\_nacimiento, id\_miembro\_fk.

#### Atributos:

- o **Id:**describe el id de cada casa y es un entero.
- nhogar: este describe el número de hogar de cada casa correspondiente y es un entero.
- o **id\_miembro**:es el id de cada miembro y es un entero.
- o **miembro**: describe el número de miembro correspondiente a cada hogar.
- o **comuna**:describe el dominio de cada casa (id)y este puede contener los datos de "Villas de la emergencia" o "Resto de la ciudad" y es un string.

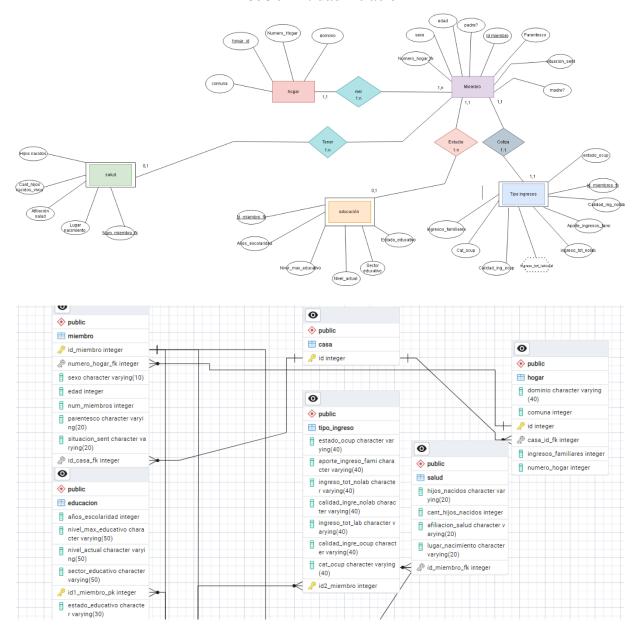
- sexo:desribe el sexo binario de cada miembro y solo recibo los datos de "Mujer" y "Varón" y es un string.
- edad: describe la edad de un miembro en años y este siempre es un número no negativo, es un entero.
- situacion\_conyugal: describe el estado civil de cada miembro y este puede contener los datos de "Soltero/a", "Viudo/a", "Unido/a", "No corresponde", "Divorciado/a"; este es un string.
- o **Dominio**:el lugar donde se encuentra cada hogar y es un stsring que contiene "Resto de la Ciudad" o "Villas de emergencia"
- o parentesco: describe el rol de la persona en el hogar y es un string.
- num\_miembro\_padre: describe el número del miembro del padre si vive en el hogar, si no vive en el hogar le otorgamos un -1 y si no corresponde -2, el tipo de dato es string.
- num\_miembro\_madre: describe el número de miembro de la madre si vive en el hogar, si no vive en el hogar le otorgamos un -1 y si no corresponde -2, el tipo de dato es string.
- estado\_ocupacional: contiene los datos de "Inactivo", "Ocupado" y "Desocupado" y es un string.
- Cat\_ocupacional: contiene la información de si la persona es o no asalariada,
   as un string
- calidad\_ingreso\_lab: Indica la calidad de los ingresos de un individuo, lo que podría incluir aspectos como la estabilidad del empleo, la regularidad de los ingresos, entre otros. Es un string.
- calidad\_ingreso\_familiares: Indica la calidad de los ingresos de un hogar, lo que podría incluir aspectos como la estabilidad del empleo, la regularidad de los ingresos, entre otros. Es un string.
- o **ingreso\_total:** Representa el ingreso total percibido por un individuo en un período determinado. Es un entero
- o **calidad\_ingresos\_nolab:** Similar a calidad\_ingreso, \_lab pero específicamente relacionado con ingresos no laborales, como rentas, intereses, etc. Es string.
- o **ngreso\_total\_nolab:** El ingreso total derivado de fuentes no laborales. Es entero.
- o ingreso\_total\_lab: El ingreso total derivado de fuentes laborales. Es entero.
- calidad\_ingresosTotales: Es la calidad de los ingresos laborales y no laborales.
   Es un string.
- o **ingresos\_familiares:** Representa el total de ingresos percibidos por una familia en un período determinado. Es un entero.

- o **ingresos\_per\_capita\_familiar**: Los ingresos totales de la familia divididos por el número de miembros de la familia. Es un entero.
- o **años\_escolaridad**: describe la cantidad de años que ha estudiado la persona y es un entero.
- estado\_educativo: Indica el estado del nivel educativo actual de un individuo, como asiste o no asiste etc. Es categórica.
- o **sector\_educativo**: Se refiere al tipo de institución educativa en la que está inscrito un individuo, como pública, privada, etc. Es un string.
- o **nivel\_actual**: El nivel educativo actual de un individuo, que podría ser grado, curso, año, etc. Es un string.
- o **nivel\_max\_educativo**: El nivel educativo máximo alcanzado por un individuo hasta el momento. Es categórica.
- cantidad\_hijos\_nac\_vivos: El número de hijos que nacieron con vida de cada miembro y es un entero.
- o hijos\_nacidos\_vivos: Describe si tiene hijos o no y es un string.
- o **afiliacion\_salud**: Describe el tipo de afiliación que tiene cada miembro y es un string.
- Lugar\_nacimiento: describe la locación de donde nació un miembro y es un string.

#### • Relaciones:

- o Reside: esta relación nos indica cuantos hogares hay por casa
- Vivir: Describe cuantas personas hay por hogar
- o Cotiza: indica los ingresos de cada miembro
- o Estudia: indica el nivel académico de cada miembro
- o Tener: indica si cada miembro tiene plan de salud

## Modelo Entidad Relación



Enlace base de datos

https://docs.google.com/spreadsheets/d/1yvxhY7NS5FK6kLnpIqBCFv5bZn3UvFZzG7IOxG MUJy0/edit?usp=sharing

Modelo Relacional normalizado en tercera forma normal

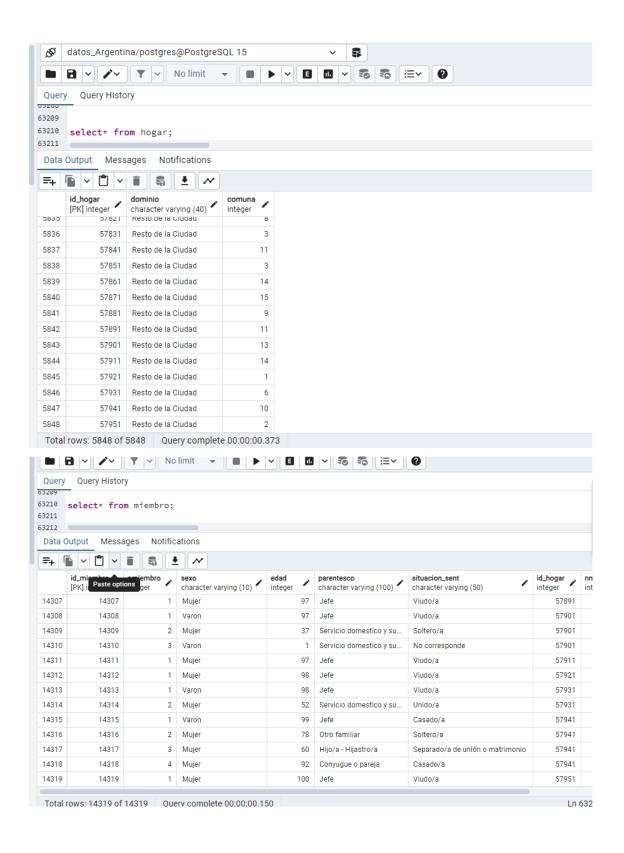
Las tablas originales de la base de datos se han normalizado a la Tercera Forma Normal para mejorar la integridad de los datos, reducir la redundancia y facilitar la actualización y el mantenimiento de la información.

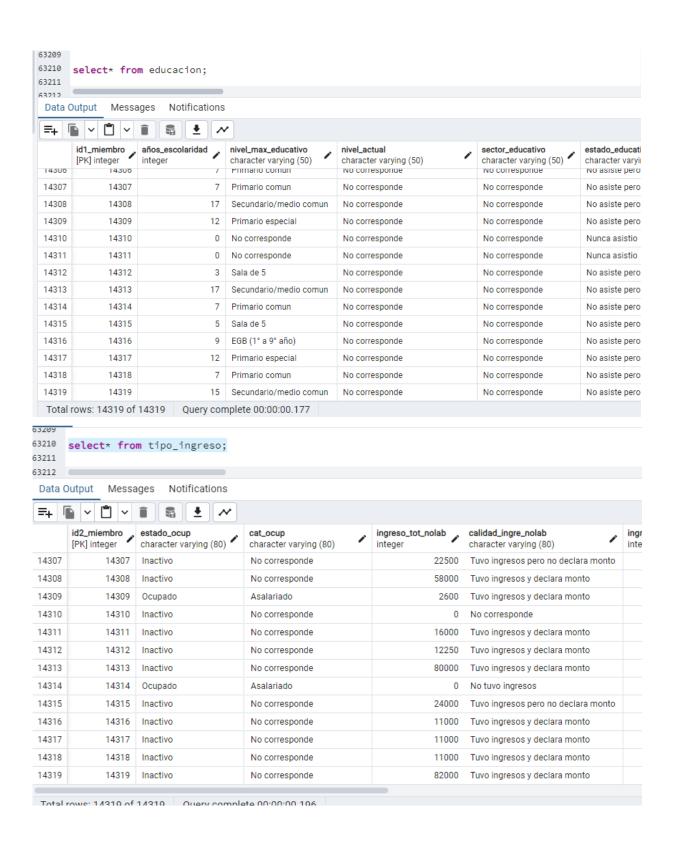
En resumen, se eliminaron algunas columnas como "tiene\_padre" o "tiene\_madre", para almacenar mejor la información, se juntaron los ingresos laborales y no laborales y se creó una sola tabla llamada ingresos, se creó una tabla para registrar el historial el educativo y se eliminó la columna "hijos\_nacidos" y se almacenó en una nueva tabla hijos.

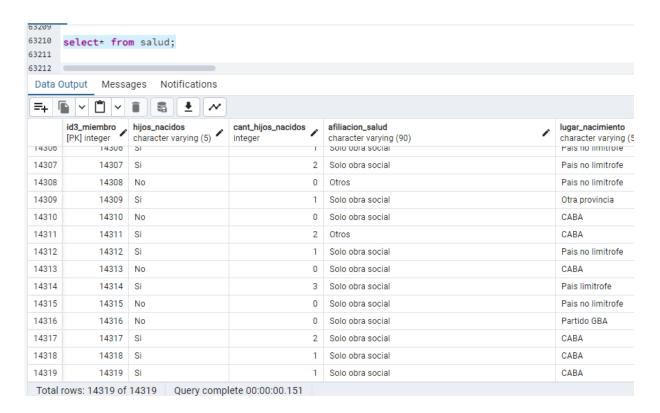
HOGAR										
id_hogar	numero_hogar	dominio	comuna	1						
MIEMBRO										
	numero_hogar	sexo	edad		padre?		nadre?	parentesco	situación_sentimental	
rino inionesco										
IPO INGRESOS d_miembro estado_ocupacional		cal_ing_no_la	ah anor in	g_familiar	cal_ocupacional		cal_ing_ocupacional	ing_tot_nolab	ing_tot_laboral	ing_familiares
a_membro	estado_ocupacionat	cat_mg_no_t	apor_iii	<u></u>	cat_ocupacio	mat  c	cat_mg_ocupacionat	IIIg_tot_Hotab	mg_tot_taborat	mg_iaimidares
EDUCACION										
id_miembro	años_escolaridad	nivel_max_ac	ad nivel_ad	tual	sector_educativo		estado_educativo			
SALUD										
	lugar_nacimiento	afiliacion_sa	lud cant_hij	os_nacvivos	hijos_nacido:	s				]
										T
HOGAR										
id_hogar	numero_hoga	ır								
.s_nogui	, idinicio_noge									
DIRECCION										
id_direction	dominio	con	nuna							
RESIDE										
id_reside	id_miembro	id_k	iogar	id_direco	ion					
PARENTESCO										
id_parentesco	parentesco									
FAMILIAR						1				
id_familiar	id miembro	id r	arentesco	sexo		+				
Id_ramiliai	ia_miembro	110_1	arentesco	Seno		_				
OCUPACION										
id_miembro	estado_ocupa	acional								
INGRESOS										
id_ingreso	id_miembro	tipo	_ingreso	cantidad		calida	d			
	_									
ESCOLARIDA										
id_miembro	años_escolar	idad								
TRAYECTORI	•									
id_trayectoria	id_miembro	pius	l_actual	sector e	ducativo	estado	o_educativo			
	is_internitio	11146	_ 40,441	20001_6	-304010	25,000				
MIEMBROSAI	LUD									
id_miembro	lugar_nacimie	nto afili	acion_salud							
HIJOS										
id_hijo	id_miembro	vivo	)							

## Descripción del proceso de carga

Se llevó a cabo una carga máxima de datos mediante la función 'INSERT INTO' en cinco tablas diferentes del sistema de bases de datos. Antes de iniciar el proceso, se verificó la integridad de los datos para asegurar que cumplieran con las restricciones de cada tabla, incluyendo claves primarias y restricciones de valor único. La operación se ejecutó dentro de transacciones para garantizar la consistencia de los datos, con un riguroso control de errores para manejar cualquier anomalía durante la inserción. Se mantuvo un registro detallado de la carga para auditar el proceso y cualquier error encontrado.







#### Descripción de análisis identificados

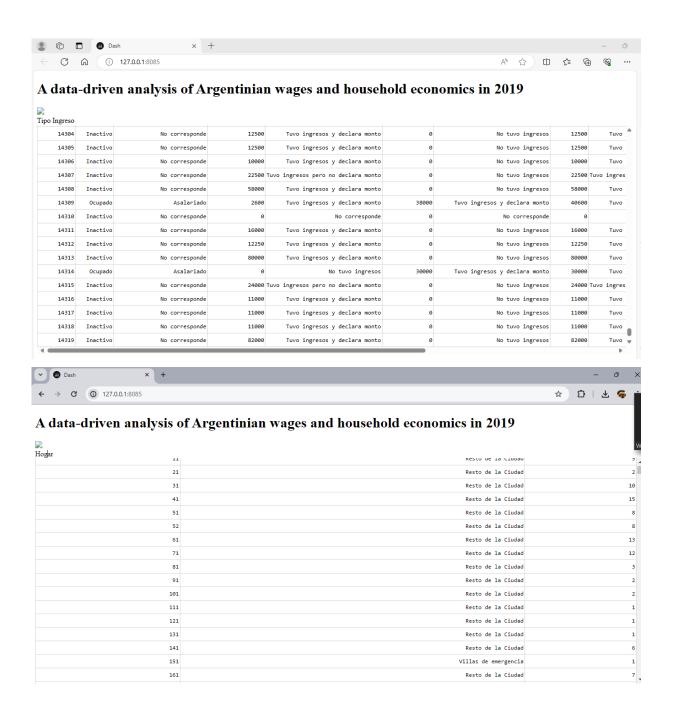
- El primer escenario es analizar los ingresos (ingreso\_total) de las personas que terminaron sus estudios universitarios (nivel\_max\_educativo) y compararlo con las personas que no los han completado.
  - Este escenario ayudaría a comprender y cuantificar los posibles beneficios de hacer un pregrado en la Argentina de 2019, respondiendo preguntas como ¿Qué tanto crece tu salario? ¿Vale la pena hacer un pregrado? ¿Estos beneficios cambian si la institución era pública o privada (sector\_educativo)?
- 2. El segundo escenario es analizar la situación laboral (estado\_ocupacional, cat\_ocupacional, calidad\_ingreso\_lab) de la gente que vive con sus padres (num\_miembro\_padre y num\_miembro\_madre) vs la gente que no.
  Haciendo este análisis podríamos ver cómo vivir con los padres afecta la situación
  - laboral y viceversa. ¿La gente que vive con sus padres gana menos? ¿La gente que vive sin sus padres tiene índices más bajos de desempleo? ¿Qué tipos de trabajo tienen las personas que viven con sus padres vs las que no? Son algunas de las preguntas que se pueden realizar.

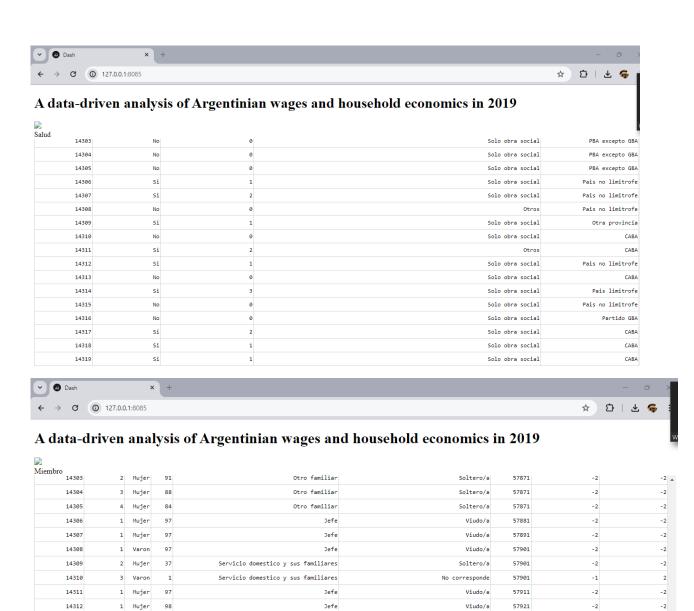
- 3. Otro escenario es ver cuántas familias con cabeza de hogar mujer (edad, parentesco) superan el salario mínimo en argentina durante el 2019, comparándolo con las de cabeza de hogar hombre.
  - Teniendo en cuenta el tamaño y variedad de la base de datos, analizar esto nos daría un vistazo en la desigualdad de género en argentina, respondiendo preguntas como ¿cómo afecta el salario ser madre cabeza de hogar? ¿Es más común estar en condiciones precarias siendo mujer?
- 4. Además, se pueden comparar los ingresos familiares (ingresos\_familiares, ingresos\_per\_capita\_familiar) y el salario (ingreso\_total\_lab) según el tipo de escolaridad que tiene una persona (sector\_educativo), estudiando actualmente en una universidad pública o privada.
  - Hacer esta proporción entre ingresos familiares y salario y analizarlo según el tipo de institución nos puede ayudar a entender quiénes necesitan trabajar mientras estudian y quiénes pueden depender de sus padres, respondiendo preguntas como, ¿los estudiantes de universidad privada necesitan trabajar más para sostenerse? ¿Los sostiene más la familia? ¿Cuántos estudian y trabajan y dónde estudian?
- 5. Otra situación por analizar es comparar los salarios (ingreso\_total\_lab) según los distintos lugares de nacimiento (Lugar\_nacimiento) presentes en la encuesta. Con esto se conocería qué ciudades tienen mejores oportunidades laborales, sobre todo al compararse con el costo de vida de cada ciudad (aunque esta información no se encuentra en la base de datos), respondiendo preguntas como ¿Cuál es la ciudad con mayores salarios? ¿Qué ciudades son más igualitarias?
- 6. La sexta situación es la comparación del nivel de educación (nivel\_max\_educativo) según el tamaño de las familias (cantidad de personas que comparten el mismo id). Teniendo en cuenta el alto costo de estudiar (tanto en matrículas como en demorarse a entrar al mercado laboral) es importante analizar si el tamaño de las familias incluye en lo que se permite que gasten en educación, respondiendo preguntas como ¿Las familias más grandes tienen hijos menos educados?
- 7. La última situación para analizar es ver si las personas con ingresos per cápita superiores a la media (ingresos\_per\_capita\_familiar) tienen salarios superiores a la media (ingreso\_total\_lab). Así se vería la influencia de la afluencia en el trabajo en la

Argentina de 2019, respondiendo preguntas como ¿Qué tanta influencia tiene venir de una familia acomodada a la hora de tener trabajo? ¿Entre la gente que logró un trabajo con altos ingresos cuántos vienen de familias acomodadas?

## Descripción proceso creación módulos de consulta en Python

Para crear los módulos de consulta en Python, empezamos con los códigos hechos en clase con el profesor. Posteriormente, nos dimos cuenta de la necesidad de organizar esta información en tablas. Inicialmente, intentamos colocar todas las consultas en un mismo servidor. Pero descubrimos que el servidor no podía manejar la carga, así que decidimos crear cada consulta por separado. Creamos 5 archivos distintos que permiten visualizar todos los datos de cada tabla creada en PostgreSQL. El formato resultante es el siguiente:





Viudo/a

Unido/a

Casado/a

Soltero/a

Casado/a

Viudo/a

Separado/a de unión o matrimonio

57931

57931

57941

57941

57941

57941

57951

14313

14314

14315

14316

14317

14318

14319

98

52

99

78

60

92

100

Servicio domestico y sus familiares

Jefe

Otro familiar

Hijo/a - Hijastro/a

Conyugue o pareja

Varon

Mujer

Varon

Mujer

Mujer

Mujer

1 Mujer

-2

-2

-2

-2

-2

-2

-2

-2

-2

-2

-2

-2

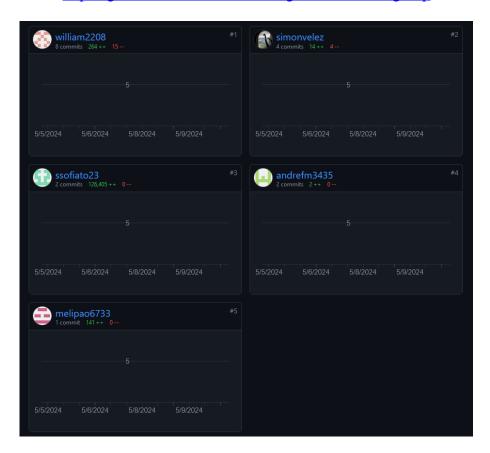
-2 🗸



Todos los códigos se encuentran en el siguiente enlace:

## **Enlace repositorio GIT**

https://github.com/andrefm3435/ing\_datozzz\_best\_group



William2208: William Cabrera

Simonvelez: Simón Vélez

Ssofiato23: Sofía Torres

• Andrefm3435: Andrés Felipe Miranda

• Melipao6733: Paola Cortés